

从点预测误差到受约束调度价值

电价预测的目标重构与冻结集成评估

独立技术研究报告

证据核验日期：2026 年 9 月 15 日

摘要

本项目的电价预测服务于一个受约束的日内调度任务：选择连续八格充电、随后连续八格放电，或者全天空闲。研究从原始评价逻辑的失败出发：在保存的候选模型中，更低的点预测 RMSE 未能稳定对应更高的实现调度价值。本文通过可行动作的几何结构解释这一失配，将学习目标重构为最大化预测器所诱导动作的实际价值，并以日中心块和回归、窗口 listwise 损失及冻结五种子曲线平均实现。指定 59 日评价期内，协议日均实现分为 **6693.88**，相对历史 MSE Transformer 参考的 **6214.36**，取得 **479.51 (7.72%)** 的观测提升。窗口排序一致性与实现分的描述性关联强于点误差，但训练代理损失本身未呈现稳定关联。收益增量也较集中：总净增益的 86.0% 来自一天，配对七日块重采样区间为 $[-227.87, 1626.28]$ ；同期主方案的最差单日实现分也低于参考。本文的贡献是可追溯的失败分析、目标重构与实现，以及一个取得正向结果的冻结协议；跨时期改善和损失函数的独立因果贡献仍需验证。

关键词：电价预测；预测后优化；受约束调度；排序学习；集成评估。

1 简介 (Introduction)

本项目首先面对一个实际问题：电价曲线预测得更准，是否就能选出更好的充放电时段？预测系统最终服务于决策，但逐点误差与调度价值关注的对象不同。前者对整条曲线上的误差累计计分；后者取决于可行窗口之间的价差，以及这些价差诱导出的单个动作。因此，在有限样本上训练出的候选模型，可能在两个指标下具有不同排序。

本文考察的历史点预测候选按平方误差评价。将保存的预测曲线接入同一个调度求解器后发现：点误差更大的 contextual Transformer，可能取得更高的实现分。这一失败推动了本文的主线：明确原始学习问题，识别其间接服务的决策结构，重构学习目标，设计可训练的代理，再评价由此形成的冻结协议。

本文的贡献限定在三个方面。第一，将观察到的失配与决定调度遗憾的可行动作差方向联系起来。第二，在全部 3321 个活动窗口上实现块级回归与 listwise 学习，并在五个固定种子的预测曲线平均后执行合法调度。第三，核对预测与评分的数据来源，报告实际增益，同时区分描述性分解与因果归因。这些贡献属于具体任务的建模、实现与评价；本文不主张提出新的通用学习定理，也不主张某一损失普遍优于其他方法。

2 相关工作 (Related Work)

电价预测与点精度。 电价预测综述重视模型比较、评价协议与可复现基准 (Lago et al., 2021)。LightGBM 等树模型为表格型特征提供了常用基线 (Ke et al., 2017)。本项目使用匿名价格序列；上述研究提供方法背景，并不能据此认定项目数据来自某个特定电力市场。

面向下游优化的学习。 预测后优化研究通过预测所诱导的决策评价预测器。Smart Predict-then-Optimize 提出了决策感知损失及 SPO+ 代理 (Elmachtoub and Grigas, 2022)，提示我们应区分点预测误差、预测决策价值与实际结算价值。本文主方法不直接对离散求解器求导，而是在有限活动窗口的价值上构造平滑训练代理。

排序学习与集成。 Mandi et al. (2022) 将决策学习表述为排序问题。本文采用相关的 listwise 构造, 分别设置真实目标温度和预测温度, 并加入日中心块和误差。独立初始化模型集成也已有广泛研究 (Lakshminarayanan et al., 2017)。本项目的具体做法是先平均价格曲线, 再选择一个合法动作; 它并不等于已经建立校准的预测不确定性估计。本文重点在于这些思想与当前动作合同的结合及证据核验。

3 问题设置：由失败驱动的目标重构 (Problem Setup)

设 X 为日调度决策时可用的输入, $A \in \mathbb{R}^{96}$ 为之后观察到的真实价格, $\mathcal{I}_{\text{dec}}$ 为决策时的信息集。时间下标为 $t = 0, \dots, 95$, 预测曲线记为 $q = f_{h,\theta}(X)$ 。

3.1 第一步：写清原始学习问题

$$\begin{aligned} & \underset{h,\theta}{\text{minimize}} && \mathbb{E} \left[\frac{1}{96} \|f_{h,\theta}(X) - A\|_2^2 \right] \\ & \text{subject to} && h \in \mathcal{H}, \quad \theta \in \Theta_h, \\ & && \mathcal{H} = \{\text{GBDT, ridge, weekday-slot mean,} \\ & && \text{DLinear, LSTM, Transformer, fixed blend}\}, \\ & && f_{h,\theta}(X) \text{ is } \mathcal{I}_{\text{dec}}\text{-measurable.} \end{aligned} \quad (1)$$

其中, h 表示允许的预测规则, θ 是对应参数空间 Θ_h 中的参数。“对 $\mathcal{I}_{\text{dec}}$ 可测”意味着预测只能由决策时已经可得的信息计算出来, 不能使用未来真实价格。预测规则属于搜索空间约束, 因此用 subject to 明确列出。 $\mathcal{H}$ 枚举的是第 6 节点损失候选集中实际出现的族: 梯度提升树 (LightGBM、XGBoost、CatBoost、HistGB)、岭回归、按星期与时段分组的历史样本均值、DLinear、LSTM、Transformer, 以及一个混合预测规则。其中混合是已有预测的后处理, 不是新的基础模型族; 其权重在 v2 验证网格中选定, 评价时固定为 $0.75q_{\text{Transformer}} + 0.25q_{\text{LightGBM}}$ 。固定规则参数空间可以是单点集合。式 (1) 概括点精度准则; 实际拟合还包含正则化、固定预算和选模限制, 不表示所有候选均精确解出了同一个无正则经验优化问题。

在样本固定、各点等权且只施加单调平方根变换时, 整体 RMSE 是平均平方误差的单调平方根, 最小化二者得到相同的最优解。式 (1) 是总体形式, 实际训练使用其有限样本版本。它直接追求的是整条价格曲线的点精度。

核心结论。 原始目标规定了哪些价格误差应被减少, 但没有直接优化这些预测所诱导调度的价值。

3.2 第二步：写清预测之后真正要解决的决策问题

$$\begin{aligned} & \underset{u}{\text{maximize}} && q^\top u, \quad q = f_{h,\theta}(X) \\ & \text{subject to} && u \in \mathcal{U}_{8+8}, \\ & && \mathcal{U}_{8+8} = \{0\} \cup \{u^{(c,d)} : (c,d) \in \mathcal{W}\}, \\ & && \mathcal{W} = \{(c,d) \in \mathbb{Z}^2 : 0 \leq c \leq 80, c+8 \leq d \leq 88\}, \\ & && u_t^{(c,d)} = P(\mathbf{1}_{d \leq t < d+8} - \mathbf{1}_{c \leq t < c+8}), \quad P = 1000. \end{aligned} \quad (2)$$

共有 $\sum_{c=0}^{80} (81-c) = 3321$ 个活动, 另加一个全零空闲动作。每个活动以固定编码功率连续充电八格, 再连续放电八格, 其余时刻功率为零。将求解器按记录中的确定性破同分规则选出的最大化动作记为 $u^*(q)$ 。实现分为 $S(A, q) = A^\top u^*(q)$; oracle 为 $O(A) = \max_{u \in \mathcal{U}_{8+8}} A^\top u$ 。

求解器依据预测 q 锁定动作, 之后才用真实价格 A 结算。项目采用的原始分数是价格乘编码功率的直接求和, 没有乘以 0.25 小时。本文使用“原始调度分数”, 不将它解释为人民币或扣除成本后的交易利润。

核心结论。预测通过所选的合法动作影响最终价值。“预测赚多少”与“实际实现多少”必须分别计算。

3.3 第三步：明确我们观察到了什么失败

$$\begin{aligned} \text{RMSE}(q_{v1}) &= 0.519558 < 0.682788 = \text{RMSE}(q_{v2}), \\ \bar{S}(q_{v1}) &= 5637.17 < 6214.36 = \bar{S}(q_{v2}). \end{aligned} \quad (3)$$

这里两条曲线分别来自 $v1$ 与 $v2$ 候选集的 contextual Transformer，均在相同 59 日上评价。RMSE 与实现分都对应实际保存并结算的同一条预测曲线。点误差更低的曲线，实际调度分反而更低。这个例子否定了这些已拟合候选之间的单调排序关系；由于配方也有变化，它不是只改变单一参数的控制实验。第 6 节再展示完整候选集。

核心结论。失败发生在本项目用点误差衡量候选调度价值的逻辑上；不能据此宣称 MSE 在所有预测任务中都是错误目标。

3.4 第四步：从可行集解释为什么可能失配

$$\begin{aligned} &\underset{u}{\text{maximize}} \quad (aq + b\mathbf{1})^\top u \\ &\text{subject to} \quad u \in \mathcal{U}_{8+8}, \quad a > 0, \\ &\quad \arg \max_{u \in \mathcal{U}_{8+8}} (aq + b\mathbf{1})^\top u = \arg \max_{u \in \mathcal{U}_{8+8}} q^\top u. \end{aligned} \quad (4)$$

对于 $\mathcal{U}_{8+8}$ 中的每个动作，都有 $\mathbf{1}^\top u = 0$ 。价格的共同偏移会在充放电价差中抵消；正比例缩放则保持窗口排序及空闲判断的符号。因此最大化解集不变，采用固定破同分规则时动作也不变。实际代码先取距最大活动分不超过 $64\varepsilon_{64} \max_w |S_w|$ 的首个窗口（先按充电起点、再按放电起点排序）；其预测分不高于零时选空闲。该实现将机器精度内近同分视作同分，故公式讨论精确算术下的解集，不宣称浮点动作在任意极端缩放下严格不变。然而，RMSE 一般会随偏移或缩放改变。该性质依赖于当前能量编码平衡的动作合同，加入损耗、费用或不对等能量流后需要重新检验。

$$\begin{aligned} R(A, q) &= A^\top (u_A - u_q) \geq 0, \quad e = A - q, \\ \mathcal{D} &= \text{span}\{u - v : u, v \in \mathcal{U}_{8+8}\}, \\ R(A, q) &\leq e^\top (u_A - u_q) \leq \|\Pi_{\mathcal{D}} e\|_2 \|u_A - u_q\|_2. \end{aligned} \quad (5)$$

以下遗憾不等式针对精确最大化动作；代码的机器精度破同分与数值验收容差另行区分。其中， $u_A = u^*(A)$ 为预知真价的最优动作， $u_q = u^*(q)$ 为预测诱导动作， $\Pi_{\mathcal{D}}$ 是到可行动作差空间的正交投影。由于 u_q 对预测 q 最优，有 $q^\top (u_A - u_q) \leq 0$ ，从而得到第一个上界；再经投影和 Cauchy-Schwarz 不等式得到第二个上界。与所有动作差方向都正交的预测误差，不会改变动作之间的相对价值。即使误差落在相关方向上，同样的误差大小也可能处于不同的决策边界距离。

核心结论。调度遗憾取决于沿可行动作差方向的误差及决策间隔。整条曲线误差范数更小，并不足以决定有限候选模型的实际收益排序。

3.5 第五步：据此重新定义学习目标

$$\begin{aligned} &\underset{h, \theta}{\text{maximize}} \quad J(h, \theta) = \mathbb{E} \left[A^\top u^*(f_{h, \theta}(X)) \right] \\ &\text{subject to} \quad h \in \mathcal{H}, \quad \theta \in \Theta_h, \\ &\quad q = f_{h, \theta}(X) \text{ is } \mathcal{I}_{\text{dec}}\text{-measurable}, \\ &\quad u^*(q) \in \arg \max_{u \in \mathcal{U}_{8+8}} q^\top u. \end{aligned} \quad (6)$$

$$\begin{aligned} & \underset{h, \theta}{\text{minimize}} \quad \mathbb{E} \left[\max_{u \in \mathcal{U}_{8+8}} A^\top u - A^\top u^*(f_{h, \theta}(X)) \right] \\ & \text{subject to} \quad (h, \theta, q, u^*) \text{ satisfy the constraints in (6).} \end{aligned} \quad (7)$$

外层选择预测器，目标是让它最终诱导出的动作获得尽可能高的实际价值；内层只根据预测选择合法动作。由于 oracle 项不依赖预测器，最大化实现价值等价于最小化相对 oracle 的期望遗憾。训练时真实标签可以提供监督，评价时真实标签可以结算已经锁定的动作，但这两种用途都不允许未来标签进入当时的决策。

$$\mu(X) = \mathbb{E}[A \mid X], \quad \mathbb{E}[A^\top u \mid X] = \mu(X)^\top u \quad (u \text{ is } \sigma(X)\text{-measurable}). \quad (8)$$

这个恒等式是必要的理论边界：若价格具有有限二阶矩、不限制模型能力，并且可以最小化基于 X 的总体平方误差，那么在同样使用 X 的决策中，条件均值就是固定可行集下风险中性线性收益的最优预测。因此，本项目重构目标的理由是有限数据、受限模型、正则化、优化误差及可能的分布变化，而不是推翻条件均值的总体最优性。式 (6) 也仍然是风险中性目标，尚未加入显式尾部风险惩罚。

核心结论。目标重构旨在让现实训练限制下的学习更贴近任务。可训练的代理损失是一种实现选择，不会自动带来更优决策。

3.6 第六步：区分本次动作合同与完整电池约束

$$\begin{aligned} & \underset{c, d, s}{\text{maximize}} \quad \sum_{t=0}^{95} q_t(d_t - c_t) \Delta t \\ & \text{subject to} \quad s_{t+1} = s_t + \frac{\Delta t}{E_{\max}} \left(\eta_c c_t - \frac{d_t}{\eta_d} \right), \\ & \quad 0.1 \leq s_t \leq 0.9 \quad (t = 0, \dots, 96), \quad s_0 = s_{\text{init}}, \\ & \quad 0 \leq c_t \leq P_c, \quad 0 \leq d_t \leq P_d, \quad c_t d_t = 0, \\ & \quad d - c \in \mathcal{U}_{8+8}^{\text{phys}}, \quad \Delta t = 0.25 \text{ h}. \\ & \quad \mathcal{U}_{\text{deploy}} = \mathcal{U}_{\text{strategy}} \cap \mathcal{U}_{\text{battery}}. \end{aligned} \quad (9)$$

这里， c_t, d_t 是物理充放电功率， s_t 是荷电状态 (SOC)， $E_{\max}$ 是电池容量， η_c, η_d 是效率。 $\mathcal{U}_{8+8}^{\text{phys}}$ 将同样的窗口策略写成物理功率形式。买卖策略和电池约束必须同时满足；若要求日末恢复初始电量，还需额外规定 $s_{96} = s_0$ ，不能从已有约束中自动推出。

例如，仅作理论说明：容量 4 MWh、初始 SOC 为 50%、充电功率 1 MW、效率为 1 时，连续充电八个 15 分钟时段会增加 2 MWh，SOC 达到 100%，超过 90% 上限。因此满足 8+8 不自动满足电池物理约束；效率低于 1 时，等长等功率充放电也不自动恢复初始 SOC。

核心结论。本文 6693.88 的结果仅在 $\mathcal{U}_{8+8}$ 下成立。SOC、容量、效率、循环成本和网络约束属于扩展模型，尚未由这组实验实现或验证。


4 方法 (Method)

4.1 将点价格映射为求解器实际使用的量

$$C = I - \frac{\mathbf{1}\mathbf{1}^\top}{96}, \quad (Bq)_j = \sum_{t=j}^{j+7} q_t \quad (0 \leq j \leq 88), \quad g_{(c,d)}(q) = (BCq)_d - (BCq)_c. \quad (11)$$

$$(u^{(c,d)})^\top q = P g_{(c,d)}(q), \quad R(A, q) \leq 4P \|BC(A - q)\|_\infty. \quad (12)$$

A TRAINING: learn relative window value



B EVALUATION: freeze the recipe, then settle a legal action



Conceptual diagram • No evaluation labels enter the predictor or action choice.

图 1: 目标重构的实现流程。此图由 Python 绘制，为概念示意。训练标签监督块价值与窗口分布；推理时平均五条冻结预测曲线，再求解一个合法动作。真实评价价格仅进入结算。训练的 3321 类分布不含空闲，推理求解器则包含空闲。中英文报告共用此英文矢量图。

算子 C 去除日均价格水平；矩阵 $B \in \mathbb{R}^{89 \times 96}$ 生成 89 个相互重叠的八格块和， $C \in \mathbb{R}^{96 \times 96}$ ， $g(q) \in \mathbb{R}^{3321}$ 。每个活动窗口的价值，是两个块和之差再乘 P 。式 (12) 中，每个活动动作的估值误差不超过 $2P\|BC(A - q)\|_\infty$ ，而遗憾比较两个动作，因此可得该上界。这解释了关注块误差的依据，但不能推出最小化块 MSE 就等价于最小化遗憾。

部分历史块模型输出的是块均值，对应块和应乘以八。常数倍不改变动作排序，却会改变损失尺度与 softmax 温度。本文损失使用块和，并省略共同的调度分数乘数 $P = 1000$ 。

4.2 从最优窗口硬标签推进到软排序目标

$$\begin{aligned}
 L_{\text{block}}(q, A) &= \frac{1}{89} \|BCq - BCA\|_2^2, \\
 \pi_w(q; \tau) &= \frac{\exp(g_w(q)/\tau)}{\sum_{v \in \mathcal{W}} \exp(g_v(q)/\tau)}, \\
 L_{\text{hard}}(q, A) &= L_{\text{block}}(q, A) - \lambda \log \pi_{w_A}(q; \tau), \quad w_A \in \arg \max_{w \in \mathcal{W}} g_w(A).
 \end{aligned} \tag{13}$$

原始窗口损失将块估值误差与单一 oracle 窗口的交叉熵相结合。代码以末日中心的真价计算硬标签 $\arg \max$ ；共同日均值在两个八格块之差中抵消，故精确算术下同一最大值集合不受影响。硬标签使用张量 $\arg \max$ 的首个最大值，不等同于调度器的近同分容差规则。但“没有把某个窗口排第一”不等于实际价值差：候选可能选择另一个近最优或同分窗口。因此，将目标推广为全部活动窗

口上的软分布：

$$\begin{aligned}
 p_w(A) &= \frac{\exp(g_w(A)/\tau_{\text{tgt}})}{\sum_{v \in \mathcal{W}} \exp(g_v(A)/\tau_{\text{tgt}})}, \\
 L_{\text{list}}(q, A) &= L_{\text{block}}(q, A) - \lambda \sum_{w \in \mathcal{W}} p_w(A) \log \pi_w(q; \tau_{\text{pred}}), \\
 \underset{\theta}{\text{minimize}} \quad & \frac{1}{N_{\text{train}}} \sum_{i \in \mathcal{T}} L_{\text{list}}(f_{h,\theta}(X_i), A_i) \\
 \text{subject to} \quad & h = \text{Transformer}, \quad \theta \in \Theta_h, \\
 & \lambda = 2, \quad \tau_{\text{tgt}} = 0.05, \quad \tau_{\text{pred}} = 0.10.
 \end{aligned} \tag{14}$$

目标温度控制近最优窗口可以保留多少概率质量，预测温度控制预测分布的尖锐程度。这些数值是最终集成中已经冻结的配方参数，没有根据本报告的诊断结果重新调节。真实价格生成的目标分布不参与求导；训练只对块和及 softmax 等可微映射求导，离散 argmax 留在评价环节。

当 $\tau_{\text{tgt}} \rightarrow 0$ 时，目标概率趋向最大值集合上的均匀分布。只有最优窗口唯一、且其他设置相同时，才退化为单一窗口的硬标签损失。这是损失族之间的极限联系，不能用来证明所选 listwise 配方优于旧损失。

固定温度的交叉熵对预测 q 的正比例缩放敏感，动作本身却不变。块误差项有助于锚定幅度，但两项并没有使总损失成为尺度不变的决策指标。因此，Results 会检验原样计算的训练代理，并如实报告其关联较弱。此外，分类目标只覆盖活动窗口，没有显式监督何时应选择空闲。

4.3 冻结配方，先平均曲线，再求解动作

$$\bar{q} = \frac{1}{5} \sum_{k=42}^{46} f_{\theta_k}(X), \quad \bar{q}^\top u = \frac{1}{5} \sum_{k=42}^{46} f_{\theta_k}(X)^\top u, \quad u_{\text{ens}} = u^*(\bar{q}). \tag{15}$$

由于收益对预测价格是线性的，对固定动作估值可以与曲线平均交换顺序，但 argmax 不能与平均交换。直接平均多个合法动作的功率，可能得到不符合固定 8+8 模式的曲线；先平均价格，再运行精确求解器，能够输出一个合法动作。最终流程在集成评价前固定模型族、损失参数、训练轮数、五个种子和曲线平均规则。其他保存的组合只作对照，不据评价结果替换主方案。

SPO+、pairwise 与可微黑盒等路线属于更广的探索记录。本文主方法限定为上述 listwise 配方与曲线平均，而不把所有决策学习路线概括成一定有效。

5 实验设置 (Experimental Setup)

5.1 数据、时间角色与信息可用性

表 1: 数据与时间角色。天数指完整标签日，不等于日期跨度内的全部日历日。

角色	日期 / 规模	允许用途
已有标签	2025 年 34,922 点；360 个完整日	不完整日不参与按日训练与评价。
内部训练	2025-01-02 至 10-03；271 日	拟合候选模型及训练内预处理参数。
验证集	2025-10-04 至 11-02；30 日	依据开发数据选择配方及轮数规则。
最终开发集	2025-01-02 至 11-02；301 日	各固定种子按冻结轮数重新拟合。
评价集	2025-11-03 至 12-31；59 日、5664 点	结算固定预测，并进行本文回顾性诊断。
另一个无标签时段	2026-01-01 至 02-28；59 日	仅有提交输入，不构成本文的实现分证据。

表 1 描述主方案的验证与重拟合路线。历史点候选保留各自原有的拟合规则，R1 使用的两个候选集并非同一套规则产生。v1 的 LightGBM、XGBoost、CatBoost 固定 1500 轮，HistGB 固定 300 轮，均不早停；岭回归固定惩罚，序列模型使用 287 日拟合和 14 日尾段早停验证。v2 的可调候选使用 271/30 切分选择设置和轮数，再在 301 日重拟合；固定 LightGBM 基线与星期时段均值是例外。HistGB 按 20 轮步长检查验证误差，上限 300 轮、连续三次不改善则停止选择，并非统一的 1500 轮 / 100 轮耐心规则。两个候选集在同一 59 日、由同一求解器结算，但属于两个不同的拟合过程；因此本文分别分析，不把它们合并成一个候选样本。相关规则导出至 `data/candidate_panel_rules.json`。主方案使用 67 维 contextual 特征，排除同期实际边界列及目标 A 。目标日预测边界的整日统计量，只有在整条预测边界曲线于决策前已发布时才合法。匿名文件尚不能确认该发布契约、具体市场身份及权威价格物理单位；实际业务适用性以这些条件得到核实为前提。

这 59 日在早期候选比较和 Phase B 压力分析中已经被观察过。记录中“holdout 不用于选择”的标志，仅约束最终 seed-bag 协议，不能扩展为整个研究历史均未接触该时段。因此，本文称其为历史上已暴露的评价期，不将其表述为全新、未触碰的前瞻性确认集。

5.2 动作合同、评分与聚合口径

$$\begin{aligned} S_i &= A_i^\top u_i, \quad O_i = \max_{u \in \mathcal{U}_{s+s}} A_i^\top u, \\ C_{\text{day}} &= \frac{1}{N} \sum_i \frac{S_i}{O_i}, \quad C_{\text{agg}} = \frac{\sum_i S_i}{\sum_i O_i} = \sum_i \frac{O_i}{\sum_j O_j} \frac{S_i}{O_i}. \end{aligned} \quad (16)$$

表 2: 调度合同与评价指标的实际定义。

项目	本次实现
时间与动作	每日 96 格；先充八格再放八格；编码功率 ± 1000 ；3321 个活动窗口加空闲。
决策输入	仅使用预测曲线；最佳活动预测分不高于零时选空闲。
物理约束	检查固定功率模式与先后关系；没有显式 SOC、效率、衰减或网络模型。
原始分数	$S_i = A_i^\top u_i$ ，不乘时间长度；实际负分日仍计入所有平均。
验证选模指标	日均 capture，即 C_{day} ，逐日等权；验证搜索汇总为 0.599646（具体聚合见下文）。
最终汇报指标	日均实现分及 C_{agg} ；后者按 oracle 机会价值 O_i 加权。记录中的 O_i 均大于零。
辅助诊断	同源 RMSE、日中心 RMSE、原样计算的 listwise 代理及逐日窗口秩相关均值。

在各日机会价值不同的情况下，两套 capture 口径可能产生不同排序。所选配方的 0.599646 是搜索种子 42、43 各自最佳 capture 的均值，对应第 5、20 轮；8290.24 则是各自最佳 realized 的均值，对应第 5、17 轮。两数并非同一批锁定预测的配对指标，也不是五种子袋在 val30 的得分。最终轮数由 capture 最佳轮次中位数 12.5 经 Python 舍入为 12，再按开发集比例缩放为 13。现存逐轮日志可重建这些汇总，但缺少对应 val30 曲线，不能独立重放其逐日结算。

5.3 模型、训练设置与比较组

表 3: 冻结的集成配方。各配方均使用 contextual 输入，种子 42–46，并在构造模型前设置种子。

配方 / 角色	损失参数	轮数	学习率
Listwise Transformer / 主方案	$\lambda = 2$, $\tau_{\text{tgt}} = 0.05$, $\tau_{\text{pred}} = 0.10$	13	10^{-3}
Window CE LSTM / 对照	$\lambda = 0.5$, $\tau = 0.2$	34	10^{-3}
SPO+ LSTM / 对照	$w_{\text{SPO}} = 0.5$	27	3×10^{-4}

Transformer 使用两层编码器，隐藏维度 32、四个注意力头、前馈维度 64、dropout 0.1、可学习位置张量和线性价格头。LSTM 为单层、隐藏维度 32，接线性输出头。最终拟合使用 Adam，批大小为 16 日，梯度范数裁剪阈值 1.0；缺失值填补中位数与特征标准化统计量均由训练数据计算。所选 Transformer 的验证轮数统计为 12，最终开发集拟合记录为 13 轮。本报告直接使用此前产生的预测，没有重新训练。

表 4: 按研究问题组织的比较组。

证据组	所回答的问题与仍然变化的因素
点损失候选: v1 16 条、v2 19 条	点误差能否排序调度价值? v1 固定树轮数 (HistGB 300, 其余 1500) 及序列尾段早停; v2 可调候选使用 val30, 固定基线除外。模型与特征也不同; 分别分析。
匹配 LightGBM 与历史 MSE Transformer	冻结主方案在相同日期与动作合同下取得何种结果? 并未隔离损失和训练配方。
MSE 选模指标对照	保持 MSE 训练时, 将验证选择指标从 RMSE 换成实现分会怎样?
三组五种子配方	各配方曲线平均, 相对自己的五个单种子实现分有什么变化? 不同模型族 / 损失仍分别作为对照。
历史窗口 CE 对照	已有单种子证据是否支持 listwise 全面占优? 训练轮数与其他配方设置仍有差异。

5.4 数据来源一致性与统计过程

本次分析核对五个来源目录的 62 条冻结预测曲线，包括共同时间戳和标签、保存动作的合法性、预测目标最优性、实际结算以及 oracle。点候选的散点横轴使用保存预测数组重新计算的 RMSE。有六个历史 RMSE 条目与对应结算曲线不一致，附录 A 并列保留两种来源；本报告没有覆盖原 leaderboard。

主不确定性分析使用配对循环日块重采样：块长七日，10,000 次，随机种子为 20260915 + 7。块长一日和三日作为敏感性分析，种子相应偏移。每次抽取连续循环日块并截取到 59 个位置，所有候选共享同一批抽样日，重新计算指标及候选相关性。此方法保留配对关系与部分短期依赖，但要求观测序列能够代表可比时段。区间取 bootstrap 分布的 2.5% 与 97.5% 分位数。**只重采样日期，16 / 19 条候选始终固定；区间不包含候选抽样、模型搜索与训练随机性。**它不校正历史探索，也不保证覆盖未来季节或分布漂移下的总体参数。

6 结果 (Results)

6.1 R1: 点误差能否稳定反映调度价值?

同源 RMSE 与实现分的 Pearson 相关性，在 v1 中为 +0.351，在 v2 中为 +0.005，七日块重采样区间均包含零。逐日去均值后分别为 +0.252 与 -0.108，说明这一现象并非仅由无关的日均偏移造成。v2 Transformer 的点误差名次为 19 条中的第 15，却在该点候选集中取得最高实现分。这是历史参考的来源，不意味着可以继续在同一评价期重选主方案。

核心结论。这些保存候选没有表现出稳定的负向关系，较低 RMSE 不能可靠选出较高实现价值；也不能反过来宣称误差越大，价值一定越高。




图 2: 完整 v1、v2 点损失候选集的误差与实现分。下排先去掉每日均值再计算 RMSE。每个点汇总同一批 59 日，候选均值彼此依赖且具有不确定性；相关性区间仅对固定候选共同按天重采样，见表 10。青色菱形仅标识 contextual Transformer，没有排除不利候选。

6.2 R2: 目标重构实际解释了什么？

$$T(q) = \frac{1}{59} \sum_{i=1}^{59} \text{Spearman}((g_w(q_i))_{w \in \mathcal{W}}, (g_w(A_i))_{w \in \mathcal{W}}). \quad (17)$$

原样计算的 listwise 训练代理与实现分的相关性，在 v1 为 +0.320、v2 为 -0.165。由于损失应越低越好，期望的负向关系既不稳定也不强。因此，本文不声称新的训练损失已成为更好的跨模型选模指标。

窗口排序一致性的 Pearson 关联则为 +0.849 与 +0.777，条件区间分别为 [0.472, 0.881]、[0.197, 0.852]。同分窗口采用平均秩；主定义使用 float64 的八格求和，改变归约次序会改变极少量机器精度同分，三位小数结论不变。进一步用日中心预测与真值幅度之比作线性控制，偏相关为 0.824 与 0.713，区间为 [0.448, 0.868]、[0.142, 0.807]。对训练代理应用同样的幅度控制，偏相关为 0.059、-0.361，区间为 [-0.443, 0.335]、[-0.664, 0.023]。因此两面板的敏感性处理保持一致，仍不支持代理具有稳定的候选选择能力。线性控制不是因果调整，也不能排除其他模型差异。

窗口秩和实现分都是同一对预测 / 真实窗口分向量的函数：前者评价全部窗口排序，后者读取预测 argmax 处的真实价值。高相关可能部分来自这种数学耦合；两者并非恒等，当前关联大小仍由数据决定。因此这些结果支持结构诊断，不能证明在验证期按代理排序，就能选出未来更好的模型。特别是，将外层目标 J 在同一批天上直接计算，其经验值就是实现分本身，不构成独立验证。真正的选模检验需要一个早于评价期、且未进入模型拟合的预测记录。v2 保存权重的拟合流程使用全部 301 个开发日；v1 序列模型用其中 287 日拟合、14 日早停，val30 也与拟合 / 选择日期重叠。metadata 未逐项保存拟合日期，日期范围需结合拆分记录和拟合代码追溯；这些 checkpoint 无法直




图 3: 相同候选曲线上的两种诊断。上排使用表 3 中主方案固定参数，计算真正的训练代理；下排使用尺度不变的窗口排序统计量 T 。上排检验代理而不预设它有效；下排解释决策结构，并非已经通过未来数据验证的新训练目标。

接提供完全未参与开发的 val30 证据。窗口秩区间明显不对称，v1 重采样中位数约为 0.771；本文将其作为敏感性范围，不宣称已校准的小样本覆盖率，也不对依赖日序列套用普通独立样本 BCa。

核心结论。记录支持“窗口排序与调度价值相关”，尚不支持“训练代理已经能更好地选择未来模型”这一更强命题。

6.3 R3: 冻结协议取得了什么实际结果？

表 5: 相同 59 日与动作合同下的主结果。

方案	预测分	实现分	C_{agg}	对参考差
匹配 LightGBM 基线	8402.83	5786.10	64.28%	-428.26
MSE Transformer 参考	10526.88	6214.36	69.04%	0.00
冻结 listwise 集成	4778.06	6693.88	74.37%	479.51

所有分数均为日均原始调度分数。共同 oracle 为 9000.89；预测分与实现分分开列示，不把预测值当成结算结果。

主方案日均实现分为 6693.88，参考为 6214.36，观测增益为 479.51，即 7.72%。Aggregate capture 从 69.04% 增至 74.37%。这些是固定动作合同下的真实标签结算。主方案的预测分仅为 4778.06，也再次说明不能把预测价值代替实际实现价值。

12 月 30 日，主方案得分 27836.92，参考得分 3499.50，该日差值贡献了总净增益的 86.02%；剔除该日后日均差为 68.17。按 10^{-6} 的分数容差，逐日结果为 25 胜、14 平、20 负；若把微小浮点差




图 4: 绝对分采用扩展刻度的点图; 增益柱从零开始, 并显示配对七日块区间。点估计是本时段的观测提升; 区间仅反映这些记录条件下的不确定性, 没有校正历史选择。

表 6: 主比较的逐日证据、尾部与不确定性。

统计量	结果
日均配对差	479.51
配对 IID 标准误 (仅参考)	451.62
7 日块 95% 条件重采样区间	[−227.87, 1626.28]
胜 / 平 / 负 (容差 10 ^{−6})	25 / 14 / 20
逐日差中位数	0.00
12 月 30 日占总净增益	86.02%
剔除 12 月 30 日后的日均差	68.17
胜日差值合计 / 负日差值合计	46151.09 / −17859.81
最差单日差值及日期	−3582.18 (2025-12-12)
最差单日实现分: 主方案 / 参考	−5922.66 / −2340.48
负分日数: 主方案 / 参考	1 / 2

剔除单日是事后敏感性分析; 主结果始终使用全部 59 日。区间未校正此前对评价期的多次观察。最差单日与负分日描述本时段已实现的下行, 不是尾部风险模型。

也记为获胜, 会夸大胜出次数。配对区间跨过零, 说明可重复的平均优势仍不确定, 但不改变已经观察到的 479.51 增量。

均值本身不能描述调度方要承担的下行。按同一批记录, 胜出日差值合计为 +46151.09, 落后日差值合计为 −17859.81, 二者相加即 28291.28 的总净增益。最大单日落后出现在 12 月 12 日, 为 −3582.18, 该最小值没有并列; 程序在精确并列时按日期顺序取首日, 并另存容差内全部日期。就单日实现分而言, 主方案的最差一天为 −5922.66, 参考为 −2340.48; 主方案有 1 个负分日, 参考有 2 个, 匹配基线有 3 个且最差一天为 −12064.47。因此, 相对匹配基线, 冻结协议同时改善了均值和最差单日; 相对 MSE Transformer 参考, 它提高了均值与中位数 (6984.89 对 6683.35), 却在本时段出现了更深的单日亏损。这些是本评价期内已实现的数值, 不是尾部风险模型, 也没有据此调整动作合同。

核心结论。冻结协议在完整评价窗口实现了 479.51 (7.72%) 的观测日均增量; 这份正向结果主要集中于一日, 可重复的平均优势仍未确定。




图 5: 完整逐日配对差及累计差。橙色为最大正收益日，深蓝为最大落后日，两者都保留在主结果中并分别标出。剔除某日仅作为敏感性计算，没有另选评价窗口。

6.4 R4: 哪些证据能够支持改善的解释？

$$\underbrace{6693.8750 - 6214.3618}_{479.5132} = \underbrace{6375.3549 - 6214.3618}_{160.9932} + \underbrace{6693.8750 - 6375.3549}_{318.5201}.$$

(18)

五个 listwise Transformer 单种子的平均分为 6375.35，曲线平均后为 6693.88，增加 318.52。式 (18)

表 7: 固定角色的集成分解；按方案角色排列，不据此重选 headline。

配方	单种子均值	种子 SD	曲线平均	集成增量
Window CE / LSTM	6050.11	242.75	6114.31	64.20
Listwise / Transformer	6375.35	118.80	6693.88	318.52
SPO+ / LSTM	6431.25	115.84	6476.01	44.76

每条配方均为种子 42–46。单种子 SD 描述这五次训练的离散度，不是时间泛化误差。

的每个数各自独立四舍五入显示，各项差值则由未舍入值计算，故按显示值相减时末位可能相差 1。相对历史参考剩余的 160.99，混合了损失、配方和拟合方式等变化，不能命名为纯粹的“损失增益”。而且，曲线平均总增量的 94.46% 也来自 12 月 30 日；剔除该日后，日均集成增量为 17.94。其他两条预先规定的袋有较小的平均增量，仍作为对照，不用于替换主方案。

表 8: 保持 MSE 训练、改变验证选模指标的现有对照。

模型族	按 RMSE 选	按实现分选	差值
Transformer	6130.30	6134.30	3.99
LSTM	5869.19	5840.46	−28.72
DLinear	6186.44	6186.44	0.00

来源为保存的对照实验；这些参考不是表 5 中所有历史模型的重新训练版本。




图 6: 固定种子的结果、单种子分数算术均值及曲线平均结果。左侧各点的纵向细微错开仅用于避免重叠, 不表示任何量。右侧围绕单种子均值分解主方案相对参考的差。这是算术恒等式, 不是损失函数或所有实现变化的独立因果效应。

已有 MSE 控制实验中, 只改变验证选模指标, Transformer、LSTM、DLinear 分别变化约 +4、-29、0。因此不能把最终改善简单解释为“只要把选模尺子换成收益就足够”。

“同初始化”只指此前 Codex 对照运行中各模型族内的分支约定, 不延伸到全部历史路线。该运行的窗口 CE Transformer 单种子分数为 6570.71, 高于 listwise 单种子均值 6375.35, 也高于其中最高种子的 6551.77。不过, 两条配方的轮数 (29 与 13)、损失参数及选择历史并不相同: 它反驳的是“跨记录全面占优”, 并不是证明旧损失因果上更好的实验。对应的 LSTM 控制比其早期记录低 137.79, 说明实现与初始化约定可能具有不可忽视的影响, 但尚不能将差值全部归于其中某一个因素。

核心结论。当前证据能够给出同一配方内的算术集成增量及选模指标对照, 尚不能隔离普遍更优的损失或可迁移的集成效应。

7 讨论与局限 (Discussion and Limitations)

7.1 理论分析提供了什么理解

本项目有价值的抽象, 是“预测器与受约束优化器的组合”。可行集决定哪些价格对比会影响动作, 学习目标决定有限模型能力如何分配到这些对比上。这解释了为什么应从决策合同推导误差诊断, 也解释了改变可行集后为何可能需要重新设计损失。遗憾上界将直觉写成明确不等式, 而条件均值的总体最优性避免将 MSE 的问题过度推广。

$$\text{Var}\left(\frac{1}{K} \sum_{k=1}^K \varepsilon_k\right) = \sigma^2 \left[\rho + \frac{1-\rho}{K} \right], \quad (19)$$

$$\text{Var}(\varepsilon_k) = \sigma^2, \quad \text{Corr}(\varepsilon_j, \varepsilon_k) = \rho \ (j \neq k).$$

若某一动作价值差的估计误差具有相同方差 σ^2 , 且两两相关系数均为 ρ , 平均后的方差如上。它提供了曲线平均可能稳定相对估值的一种机制。但本文没有估计 σ^2 与 ρ ; 即使误差方差下降, 也不能保证经过不连续 argmax 后价值一定提高。考虑到本次增量高度集中于一天, 这里应定位为机制假说, 而非已证实的改善原因。

7.2 证据边界与下一步有区分力的检验

- **时间与历史暴露。**只有 59 日，而且研究过程中此前已查看。重尾、时间依赖和历史探索限制了前瞻解释；日块区间不能消除这些限制。
- **物理与信息范围。**实际求解器未实施 SOC、损耗、衰减和网络约束。输入预测曲线的完整发布时间及数据市场来源，需要在部署前得到外部确认。
- **代理范围。**固定温度代理不是尺度不变量，在当前候选中关联较弱；其仅覆盖活动窗口的分类目标也没有学习空闲，这在低机会时期可能重要。
- **增益归因。**主方案与参考同时改变了训练配方和种子聚合。现有控制没有构成同模型族、同初始化、同预算的完整损失因子实验。
- **结果分布与下行。**外层业务目标是风险中性的期望分数；实际训练使用 MSE 或块和 / 排序代理，并不直接优化期望实现分，式 (6) 没有尾部惩罚项。本时段主方案的最差单日为 -5922.66 ，深于参考的 -2340.48 。评价样本只有 59 日且重尾，不足以可靠估计这类损失的未来发生频率；若业务对单日下行有约束，应在可行集或目标中显式加入，并重新评价。

后续最有区分力的检验有三项：在新的滚动时段比较冻结协议；使用未进入拟合的验证预测，比较 RMSE 与代理对后续实现分的排序能力；在模型族、初始化、训练预算、选择规则及种子数一致时比较损失。上述为后续建议，本报告没有执行这些新训练实验。

8 结论 (Conclusions)

失败分析表明，点预测误差未能稳定排序保存候选的实现调度价值。本文从合法动作集合出发，通过不变性与动作差遗憾解释这一现象，重构学习目标，并实现块级/listwise 代理与冻结曲线平均。在指定评价期，协议得分由参考的 6214.36 提升至 6693.88，观测增量为 479.51；其集中度、下行与不确定性同属该结果的一部分。可推广的方法认识是：学习目标应围绕预测服务的决策及约束设计，评价时则应区分合理机制、已经实现的结果，以及对未来改善的证据。

参考文献

- Adam N. Elmachtoub and Paul Grigas. Smart “predict, then optimize”. *Management Science*, 68(1):9–26, 2022. doi: 10.1287/mnsc.2020.3922.
- Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL <https://papers.nips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>.
- Jesus Lago, Grzegorz Marcjasz, Bart De Schutter, and Rafal Weron. Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293:116983, 2021. doi: 10.1016/j.apenergy.2021.116983.
- Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL <https://papers.nips.cc/paper/2017/hash/9ef2ed4b7fd2c810847ffa5fa85bce38-Abstract.html>.
- Jayanta Mandi, Víctor Bucarey, Maxime Mulamba Ke Tchomba, and Tias Guns. Decision-focused learning: Through the lens of learning to rank. In *Proceedings of the 39th International Conference on Machine*

Learning, volume 162 of *Proceedings of Machine Learning Research*, pages 14935–14947, 2022. URL <https://proceedings.mlr.press/v162/mandi22a.html>.

A 预测来源与派生证据

表 9: 历史 RMSE 与实际结算曲线的 RMSE: 保留原表, 新增同源复算。

组	模型	历史表	同源复算	实现分
v1	transformer_contextual	0.514318	0.519558	5637.17
v1	lstm_contextual	0.573845	0.552808	4554.39
v1	dlinear_contextual	0.655333	0.600021	5897.54
v2	transformer_contextual	0.630545	0.682788	6214.36
v2	lstm_contextual	0.528645	0.517490	5709.51
v2	blend_lgb_transformer	0.584431	0.617157	6041.85

本表不覆盖任何原始 RMSE/MAE 字段。其他点模型在 10^{-5} 容差内吻合。

v2 Transformer 的 6214.36 结算值对应 RMSE 为 0.682788 的保存曲线, 而不是历史表中的 0.630545。本文的两个坐标轴均与同一曲线配对, 并将复算字段单独命名; 原始表和受保护的 Phase B 指标保持不变。

由于存在同分窗口, 只比较是否命中某一个 oracle 窗口编号并不充分。其成因是目标序列本身的性质: 相邻时段价格相同的比例为 42.09%, 中位数日在 96 格中只有 35 个不同取值, 最平坦的一天只有 15 个。当常数段长于八格时, 不同窗口编号会给出相同的块和, 进而给出相同的结算值。按价值相同的数值容差判断, 主方案有五日达到 oracle 值, 参考有三日。因此不能把“某个唯一 oracle 编号零命中”解读为“从未达到最优价值”。同一性质也解释了配对结果中的平局: 14 个平局日中只有 3 日与参考选择了同一窗口, 另外 11 日选择了不同窗口但结算值完全相同。因此窗口 Spearman 诊断采用平均秩; 求解器与硬标签 argmax 仍各自使用其确定性破同分规则。空闲动作在主方案和参考记录中没有被选择, 但始终在可行集中; 预测机会为正也不保证实际结算为正。

表 10: 跨候选关联及共同按天重采样区间。

组	横轴指标	r	95% 区间	ρ	95% 区间
v1	RMSE	0.351	[−0.171, 0.535]	0.482	[−0.303, 0.638]
v1	日中心 RMSE	0.252	[−0.152, 0.382]	0.391	[−0.238, 0.559]
v1	Listwise 代理	0.320	[−0.241, 0.485]	0.374	[−0.338, 0.553]
v1	窗口排序 T	0.849	[0.472, 0.881]	0.612	[0.200, 0.812]
v2	RMSE	0.005	[−0.438, 0.333]	0.082	[−0.474, 0.321]
v2	日中心 RMSE	−0.108	[−0.488, 0.203]	−0.035	[−0.484, 0.233]
v2	Listwise 代理	−0.165	[−0.518, 0.124]	−0.039	[−0.460, 0.093]
v2	窗口排序 T	0.777	[0.197, 0.852]	0.656	[0.135, 0.814]

r 为 Pearson; ρ 为跨候选 Spearman。窗口 T 本身另含窗口内 Spearman。7 日块、10,000 次 percentile 重采样, 仅改变日期、固定候选集合; 区间不包含候选搜索或抽样不确定性。

表 11: 块长敏感性：同一冻结数据，三种重采样长度。

比较	块长	日均差	95% 区间
主方案 - 参考	7	479.51	[−227.87, 1626.28]
主方案 - 参考	1	479.51	[−195.49, 1494.13]
主方案 - 参考	3	479.51	[−203.29, 1535.28]
曲线平均 - 单种子均值	7	318.52	[−155.46, 988.44]
曲线平均 - 单种子均值	1	318.52	[−164.20, 1045.96]
曲线平均 - 单种子均值	3	318.52	[−160.66, 1009.27]

B 复现方法与证据索引

两版共用英文矢量图、派生记录与公式。定量图均由 Python 根据真实 CSV/JSON 绘制，方法图为概念示意。本文与核验脚本使用 AI 辅助整理项目已有实验，贡献主张以记录为依据。

- **编译**：上传 ZIP，主文件选 `main.tex`，编译器选 XeLaTeX；作者信息在 `author.tex` 中设置。
- **重画**：安装 `scripts/requirements.txt` 后运行 `python scripts/build_figures.py`，读取包内记录，不训练模型。
- **复算与追溯**：`scripts/derive_records.py` 需要原仓库，命令见 `README.md`。
`data/source_manifest.json` 包含准确来源、SHA-256 与依赖版本；`data/analysis_plan.json` 记录事后分析选择，不是前瞻预注册。

本版核验范围。 复核范围分为三层：保存曲线可重放结算与误差，历史控制可重放其独立保存曲线，val30 汇总只能追溯逐轮日志。后者缺少预测曲线，不能声称已独立复现结算。

- 62 条冻结预测曲线共用同一时间戳索引与同一真实标签向量；逐条检查保存动作的合法性、保存预测分是否等于求解器最优值，并逐日重算结算分与 `oracle`。
- 主方案 6693.875025 与参考 6214.361782 由曲线重新算出，式 (18) 的分解恒等式按未舍入数值断言成立。
- 胜 / 平 / 负计数断言覆盖全部 59 日；平局再拆为“同窗口”与“不同窗口但结算值相同”两类，其和断言等于平局总数。
- 六条与结算曲线不符的历史 RMSE 记录在表 9 中并列保留，原 `leaderboard` 的任何列均未改写。
- 每个受追踪的来源文件在分析前后各计算一次 SHA-256；若运行期间任一输入发生变化，即判定失败。

以上核验确立的是内部一致性与来源可追溯性，不能也无法证明本时段的增益可迁移到新的评价期；该命题需要第 7.2 节所述的滚动时段检验。